Machine Learning et Deep Learning : définitions, comparaison et critères de choix

1. Le Machine Learning (apprentissage automatique)

Le **Machine Learning (ML)** est une branche de l'intelligence artificielle dans laquelle un système **apprend à partir de données** pour accomplir une tâche, sans que les règles soient explicitement programmées. L'algorithme identifie des régularités dans des exemples, puis généralise à de nouvelles données.

Il se décline en trois grandes familles :

- **Supervisé** : les données sont étiquetées (classification, régression).
- **Non supervisé** : pas d'étiquettes (clustering, réduction de dimension).
- **Par renforcement** : un agent apprend par essais/erreurs via des récompenses.

Algorithmes typiques : régression linéaire et logistique, arbres de décision, forêts aléatoires, SVM, k-NN, k-means, gradient boosting (XGBoost, LightGBM).

Une caractéristique clé : le ML classique repose largement sur le **feature engineering**, c'est-à-dire que l'humain sélectionne et construit les variables pertinentes (ex. : extraire la surface, le quartier et l'âge d'un bien pour prédire son prix).

2. Le Deep Learning (apprentissage profond)

Le **Deep Learning (DL)** est un **sous-ensemble du Machine Learning** fondé sur les **réseaux de neurones artificiels à plusieurs couches** (d'où « profond »). Chaque couche transforme les données et extrait des représentations de plus en plus abstraites : pour une image, des contours, puis des formes, puis des objets entiers.

Sa caractéristique clé : le modèle **apprend lui-même les caractéristiques pertinentes** à partir des données brutes (pixels, texte, signal audio), sans feature engineering manuel.

Architectures courantes : réseaux convolutifs (CNN) pour l'image, réseaux récurrents (RNN/LSTM) pour les séquences, **Transformers** pour le langage (base des LLM), autoencodeurs, GAN, modèles de diffusion.

Relation d'inclusion : IA ⊃ Machine Learning ⊃ Deep Learning.

3. Comparaison

Critère	Machine Learning classique	Deep Learning
Volume de données	Fonctionne bien avec des petits et moyens jeux de données (centaines à milliers d'exemples)	Nécessite généralement de très grands volumes (dizaines de milliers à millions)
Type de données	Surtout données **structurées/tabulaires**	Excelle sur les données **non structurées** : images, texte, audio, vidéo
Extraction des variables	Manuelle (feature engineering)	Automatique
Puissance de calcul	Modeste (CPU suffisant)	Élevée (GPU/TPU souvent indispensables)
Temps d'entraînement	Minutes à heures	Heures à semaines
Interprétabilité	Souvent bonne (arbres, régressions)	Faible : fonctionnement de type « boîte noire »
Performance maximale	Plafonne sur les problèmes très complexes	Atteint l'état de l'art sur les tâches perceptives et linguistiques
Réglage	Peu d'hyperparamètres	Nombreux hyperparamètres, architecture à concevoir
Coût	Faible	Élevé (matériel, énergie, expertise)
Risque de surapprentissage	Modéré	Élevé sans régularisation ni assez de données

4. Quand utiliser l'un plutôt que l'autre ?

Privilégier le Machine Learning classique lorsque :

- Les **données sont tabulaires** (finance, CRM, scoring de crédit, prévision de ventes). Les modèles de type gradient boosting y sont souvent meilleurs que les réseaux de neurones.
- Le **jeu de données est limité**.

- L'**interprétabilité est exigée** (santé, banque, assurance, contexte réglementaire, RGPD et droit à l'explication).
- Les **ressources de calcul sont contraintes** (systèmes embarqués, budget réduit).
- Vous voulez un **prototype rapide** ou une base de référence (baseline).
- Vous maîtrisez bien le domaine et pouvez construire de bonnes variables.

Privilégier le Deep Learning lorsque :

- Les données sont **non structurées** : reconnaissance d'images, détection d'objets, reconnaissance vocale, traduction, génération de texte.
- Vous disposez de **beaucoup de données** (ou pouvez utiliser le **transfert d'apprentissage** avec un modèle pré-entraîné).
- La tâche est **très complexe** et le feature engineering manuel serait impraticable.
- La **performance prime** sur l'explicabilité (conduite autonome, diagnostic par imagerie, assistants conversationnels).
- Vous disposez de l'**infrastructure** nécessaire.

Règle pratique

Commencez simple : testez d'abord un modèle de ML classique comme référence. Ne passez au Deep Learning que si la nature des données (images, texte, son) ou le plafonnement des performances le justifie. Le transfert d'apprentissage (fine-tuning de modèles pré-entraînés) réduit aujourd'hui fortement les besoins en données et en calcul du Deep Learning.

Conclusion

Le Deep Learning n'est pas un « meilleur » Machine Learning, mais une **approche spécialisée** : très puissante sur les données complexes et massives, mais coûteuse et opaque. Le choix doit découler de la **nature des données, de leur volume, des contraintes d'explicabilité et des ressources disponibles**.