Trois applications du Deep Learning

Ce document présente trois applications du Deep Learning, inspirées de la vitrine AI Experiments de Google et des modèles d'OpenAI. Elles correspondent chacune à un type de données non structurées : le dessin, l'audio et la génération d'images.

1. Reconnaissance de dessins : Quick, Draw! (Google AI Experiments)

AI Experiments est une vitrine de démonstrations qui permet au public de manipuler des exemples d'apprentissage automatique ou d'en télécharger le code. Dans Quick, Draw!, l'utilisateur joue à une sorte de Pictionary avec un moteur de reconnaissance de croquis, et contribue ainsi à son entraînement. Le joueur dispose de 20 secondes pour dessiner six objets simples, et le système analyse non seulement la forme, mais aussi les traits utilisés pour la tracer. Il s'agit d'une approche de reconnaissance de caractères utilisée par des millions de personnes sur smartphone.

Pourquoi c'est du Deep Learning : le réseau apprend seul à reconnaître des formes à partir de données brutes (tracés), et chaque dessin recueilli enrichit les données d'entraînement.

2. Reconnaissance vocale : Whisper (OpenAI)

Whisper est un modèle de reconnaissance automatique de la parole publié par OpenAI en septembre 2022, entraîné sur 680 000 heures d'audio multilingue collecté sur Internet. C'est un modèle encodeur-décodeur multitâche, capable de transcrire la parole dans de nombreuses langues, de la traduire et de détecter la langue parlée. Ses poids sont open source sous licence MIT, ce qui a permis des adaptations comme whisper.cpp, utilisable en local et en temps réel. Les usages vont de la transcription de réunions à l'assistance vocale et à l'accessibilité.

Pourquoi c'est du Deep Learning : un Transformer apprend directement sur des signaux audio bruts, sans règles phonétiques écrites à la main.

3. Génération d'images : DALL·E (OpenAI)

DALL·E, DALL·E 2 et DALL·E 3 sont des modèles qui produisent des images à partir de descriptions textuelles appelées « prompts ». Le DALL·E original reposait sur un Transformer traitant ensemble jetons de texte et d'image, tandis que DALL·E 2 et 3 utilisent des architectures de diffusion, devenues l'approche dominante. Un modèle de

diffusion apprend à transformer progressivement une image sans signification en image cohérente, en inversant un processus d'ajout de bruit. DALL·E 3 a été intégré à ChatGPT en octobre 2023, et permet aussi de modifier ou d'étendre des images existantes.

Pourquoi c'est du Deep Learning : le modèle apprend des représentations communes au texte et à l'image à partir de millions de paires texte-image.

Lien avec le choix entre Machine Learning et Deep Learning

Ces trois cas illustrent les critères qui orientent vers le Deep Learning : des **données non structurées**, de **gros volumes** et une performance qui prime sur l'interprétabilité.

Sources

- TechCrunch, « Google's AI Experiments help you understand neural networks by playing with them » (2016)
- MIT Technology Review, « Want to Understand AI? Try Sketching a Duck for a Neural Network » (2016)
- OpenWhispr, « How Whisper AI Works » ; GeeksforGeeks, « OpenAI Whisper »
- Wikipedia, « DALL-E » ; Freethink, « How do DALL-E, Midjourney, Stable Diffusion, and other forms of generative AI work? » ; Morphic, glossaire IA, « DALL-E »